



# 不确定性知识的表示与推理

## 第十三章 不确定性的量化



# 提纲

- 第十三章 不确定性的量化
  - 不确定性的概述
  - 基本概率符号，使用完全联合分布进行推理
  - 贝叶斯规则及其应用
  - 独立性与条件独立性



# 不确定性

一个不确定性的例子：自动驾驶出租车智能体


目标：将乘客按时送到机场

规划： $A_t$  = 提前  $t$  分钟出发，并以合理的速度驶向机场。

问题： $A_t$  规划能使乘客准时到达机场吗？

环境：

1. 部分可观测的（路况，其它驾驶员规划，etc.）
2. 不确定性（车辆爆胎，引擎失灵，etc.）



# 不确定性

一个逻辑智能体可能给出的结论：

1. 有风险的断言：“规划  $A_{90}$  将使我们及时到达机场”
2. 得出如下的弱一些的结论：
3. “规划  $A_{90}$  将使我们及时到达机场，只要车不抛锚，汽油不耗尽，不遇到任何交通事故，桥上也没有交通事故，飞机不会提前起飞，……”

试图使用命题逻辑描述不确定性会失败的原因：无法列举出前提和结论的完整集合

# 处理不确定性的方法

- 不确定环境下，智能体的知识提供相关语句的**信念度** (degree of belief)，  
处理信念度的主要工具是**概率理论** (probability theory)
- 概率提供了一种方法以概括现实中的不确定性
  - **没有**关于世界的断言，概率将命题与智能体自身的知识状态联系起来：

规划  $A_{25}$  将使我们及时到达机场的概率 (可能性)  $P(A_{25}) = 0.04$

$P(A_{25} \mid \text{no reported accidents}) = 0.06$

$P(A_{25} \mid \text{no reported accidents, 5 a.m.}) = 0.15$

命题的概率随新证据而变化

# 不确定性与理性决策

- 再次考虑去机场的规划  $A_t$

$$P(A_{25} \text{ gets me there on time} \mid \dots) = 0.04$$

$$P(A_{90} \text{ gets me there on time} \mid \dots) = 0.70$$

$$P(A_{120} \text{ gets me there on time} \mid \dots) = 0.95$$

$$P(A_{1440} \text{ gets me there on time} \mid \dots) = 0.9999$$

我们该如何做选择？

- 效用理论 (Utility theory) 对偏好进行表示和推理，每个状态具有“效用”度量值


- 偏好：及时到达机场、避免在机场长时间等待、避免路上超速罚单等

- 决策理论 = 概率理论 + 效用理论

- 基本思想：一个智能体是理性的，当且仅当它选择能产生最高期望效用的行动

# 提纲

- 第十三章 不确定性的量化
  - 不确定性的概述
  - 基本概率符号，使用完全联合分布进行推理
  - 贝叶斯规则及其应用
  - 独立性与条件独立性



# 基本概率符号

---

- 概率理论

- 随机变量
- 无条件概率（先验概率）、条件概率（后验概率）
- 完全联合概率分布
- 乘法法则、链式法则
- 使用完全联合分布进行枚举推理
  - 归一化方法



# 概率逻辑

- 基本要素：随机变量，表示可能世界中的不确定性，可能世界是由对随机变量的赋值进行定义
- 布尔随机变量
  - e.g., R: Is it raining? 定义域：<true, false>
- 离散随机变量
  - e.g., Weather is one of <sunny, rainy, cloudy, snow>
- 基本命题通过单个随机变量的赋值进行构造：
  - Weather = sunny (abbreviated as sunny)
- 复合命题由基本命题的逻辑连接构造
  - e.g., Weather = sunny  $\vee$  R = false

随机变量以大写字母开头，变量的值用小写

# 概率逻辑

考虑随机变量 *Weather* , 其定义域为 *< sunny, rainy, cloudy, snow >*

P 定义了随机变量 *Weather* 的一个概率分布

每个可能取值的概率，可以写成：

$$P(\textit{Weather} = \textit{sunny}) = 0.6$$

$$P(\textit{Weather} = \textit{rainy}) = 0.1$$

$$P(\textit{Weather} = \textit{cloudy}) = 0.2$$

$$P(\textit{Weather} = \textit{snow}) = 0.1$$

**P**(*Weather*)

<i>Weather</i>	<i>P</i>
sunny	0.6
rainy	0.1
cloudy	0.2
snow	0.1

也可以简写为：

$$\mathbf{P}(\textit{Weather}) = \langle 0.6, 0.1, 0.2, 0.1 \rangle$$

(normalized, i.e., sums to 1)

# 先验概率与联合概率分布

- **先验概率** 或 **无条件概率**

e.g.,  $P(\text{Cavity} = \text{true}) = 0.164$  ;  $P(\text{Weather} = \text{sunny}) = 0.72$

- **联合概率分布** : **多个变量取值的所有组合的概率**

$P(\text{Weather}, \text{Cavity})$  是一个  $4 \times 2$  的概率表 :

	Weather =			
	sunny	rainy	cloudy	snow
Cavity = true	0.144	0.02	0.016	0.02
Cavity = false	0.576	0.08	0.064	0.08

- e.g.,  $P(\text{sunny}, \text{cavity})$  也可以记作  $P(\text{sunny} \wedge \text{cavity})$

- **完全联合概率分布** : **可能世界中所有随机变量的联合分布**

- e.g.,  $P(\text{Toothache}, \text{Weather}, \text{Cavity})$

- 一个完全联合分布基本满足计算任何命题的概率的需求

# 条件概率

- 条件概率 或 后验概率

- e.g.,  $P(A_{100} \text{ on time} \mid \text{no reported accidents}) = 0.90$

- 额外条件很重要，观察新的证据，更新信念度

- $P(A_{100} \text{ on time} \mid \text{no accidents, 5 a.m.}) = 0.95$

- $P(A_{100} \text{ on time} \mid \text{no accidents, 5 a.m., raining}) = 0.80$

- 条件概率是由无条件概率定义的：

$$P(a|b) = \frac{P(a, b)}{P(b)}$$

要求：  $P(b) > 0$

# 乘法法则和链式法则

- 乘法法则：

$$P(a, b) = P(a \mid b) P(b) = P(b \mid a) P(a)$$

- e.g.,  $P(\text{Weather}, \text{Cavity}) = P(\text{Weather} \mid \text{Cavity}) P(\text{Cavity})$

- 考虑有  $n$  个变量的联合分布：

$$P(X_1, \dots, X_n) = P(X_1, \dots, X_{n-1}) P(X_n \mid X_1, \dots, X_{n-1}) \quad (\text{乘法法则})$$

$$= P(X_1, \dots, X_{n-2}) P(X_{n-1} \mid X_1, \dots, X_{n-2}) P(X_n \mid X_1, \dots, X_{n-1}) \quad (\text{乘法法则})$$

$$= \dots \quad \dots$$

$$= \prod_{i=1 \sim n} P(X_i \mid X_1, \dots, X_{i-1}) \quad (\text{乘法法则})$$

- 链式法则： $P(X_1, \dots, X_n) = \prod_{i=1 \sim n} P(X_i \mid X_1, \dots, X_{i-1})$

# 概率推理

- 使用完全联合概率分布作为“知识库”，从中可以导出所有问题的答案。
- 概率推理：根据已观察到的证据，计算查询命题的先验概率和后验概率。
- 一个简单的例子：诊断牙病患者的牙痛
  - 问题域：由三个布尔变量 *Toothache*，*Cavity* 和 *Catch* 组成，*Catch* 表示探针不洁而导致的牙龈感染

▪ 给定

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.

# 枚举推理

- 给定完全联合分布：

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.

- 对于任意命题  $\varphi$ ，其概率是使得该命题成立的可能世界的概率之和： $P(\varphi) = \sum_{\omega: \omega \models \varphi} P(\omega)$
- 一种计算任何命题概率的方法：
  - 识别命题为真的可能世界，然后把它们的概率加起来
  - 例如： $P(\text{cavity} \vee \text{toothache}) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28$

# 枚举推理

- 给定完全联合分布：

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.

- 一个特别常见的任务：提取某个变量的概率分布（无条件概率 / 边缘概率）
- 边缘化规则，或者称为求和消元： $P(Y) = \sum_z P(Y, z)$ 
  - $P(\text{toothache}) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$



# 枚举推理

- 给定完全联合分布：

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.

- 条件概率是由无条件概率定义的，可以计算条件概率：

$$\begin{aligned}P(\neg \text{cavity} \mid \text{toothache}) &= \frac{P(\neg \text{cavity} \wedge \text{toothache})}{P(\text{toothache})} \\&= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} \\&= 0.4\end{aligned}$$

$$\begin{aligned}P(\text{cavity} \mid \text{toothache}) &= \frac{P(\text{cavity} \wedge \text{toothache})}{P(\text{toothache})} \\&= \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} \\&= 0.6\end{aligned}$$

这两个计算出来的值相加等于 1。分母是不变的，是常数。

# 归一化推理

## 归一化方法

基本思想：计算查询变量的概率分布，可以固定证据变量 (evidence variables)，然后在隐变量 (hidden variables) 上求和并归一化

假设查询变量为  $X$ ；证据变量集合为  $E$ ， $e$  表示其观察值；其余未观测变量为隐藏变量  $Y$ 。

计算查询变量：

$$P(X \mid e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

其中， $\alpha$  是归一化常数。

# 归一化推理

■ 例如：  $P(\text{Cavity} \mid \text{toothache})$

$$= \alpha P(\text{Cavity}, \text{toothache})$$

$$= \alpha [P(\text{Cavity}, \text{toothache}, \text{catch}) + P(\text{Cavity}, \text{toothache}, \neg \text{catch})]$$

$$= \alpha [<0.108, 0.016> + <0.012, 0.064>]$$

$$= \alpha <0.12, 0.08>$$

$$= <0.6, 0.4>$$

查询变量 *Cavity*;

证据变量 *Toothache* , 取值为  
*true* ;

隐藏变量 *Catch*

归一化方法：


$$P(X \mid e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

问题：规模扩展性不好

对于一个由  $n$  个布尔变量所描述的问题域，最坏情况下的时间复杂性  $O(2^n)$ ，空间复杂性  $O(2^n)$

# 提纲

- 第十三章 不确定性的量化
  - 不确定性的概述
  - 基本概率符号，使用完全联合分布进行推理
  - 贝叶斯规则及其应用
  - 独立性与条件独立性



# 贝叶斯规则

- 根据乘法法则，联合分布可以表示为：

$$P(a, b) = P(b|a)P(a) = P(a|b)P(b)$$

- 同时除以  $P(a)$ ，得到贝叶斯规则：

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

- 是大多数进行概率推理的人工智能系统的基础
- 贝叶斯规则在实践中很有用：
  - 很多情况下，前三项有很好的估计，而需要计算第 4 项

That's my rule!



# 应用贝叶斯规则

- 医疗诊断：
- 结果 *effect* 看作是证据，确定造成这一结果的未知因素 *cause*，贝叶斯规则：

$$P(\text{cause}|\text{effect}) = \frac{P(\text{effect}|\text{cause})P(\text{cause})}{P(\text{effect})}$$

- 条件概率  $P(\text{cause}|\text{effect})$  描述诊断方向上的关系
- 条件概率  $P(\text{effect}|\text{cause})$  量化了因果方向上的关系
- 实际中，经常有因果关系的条件概率，而想得出诊断关系。

# 应用贝叶斯规则

- 示例：明天要举行户外运动。近年来，每年仅下雨5天 ( $5/365 \approx 0.014$ )。不幸的是，天气预报员预测明天会下雨。当真的下雨时，天气预报员准确地预测了90%的降雨。当不下雨时，他错误地预测了10%的降雨。明天下雨和不下雨的可能性分别有多大？

- 令 rain 表示明天下雨，predict 表示预测明天下雨
- 令 rain 表示明天下雨，predict 表示预测明天下雨


- 则有：

- $P(rain) = 0.014$ ;  $P(\neg rain) = 0.986$  ;  $P(predict|rain) = 0.9$ ;  $P(predict|\neg rain) = 0.1$
- ; = ; =0.1

- 问题：计算  $P(Rain|predict)$ ?
- 问题：计算  $P(Rain|predict)$  ?

# 提纲

- 第十三章 不确定性的量化
  - 不确定性的概述
  - 基本概率符号，使用完全联合分布进行推理
  - 贝叶斯规则及其应用
  - 独立性与条件独立性





# 独立性

- 一个简单的例子：诊断牙病患者的牙痛
- 问题域：由三个布尔变量 *Toothache* , *Cavity* 和 *Catch* 组成

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.

引入第四个变量 *Weather* , 有四个取值 *<unny, rainy, cloudy, snow>*

完全联合分布： $\mathbf{P}(\textit{Toothache}, \textit{Catch}, \textit{Cavity}, \textit{Weather})$  , 有  $2 \times 2 \times 2 \times 4 = 32$  个条目。

# 独立性

- 完全联合分布：

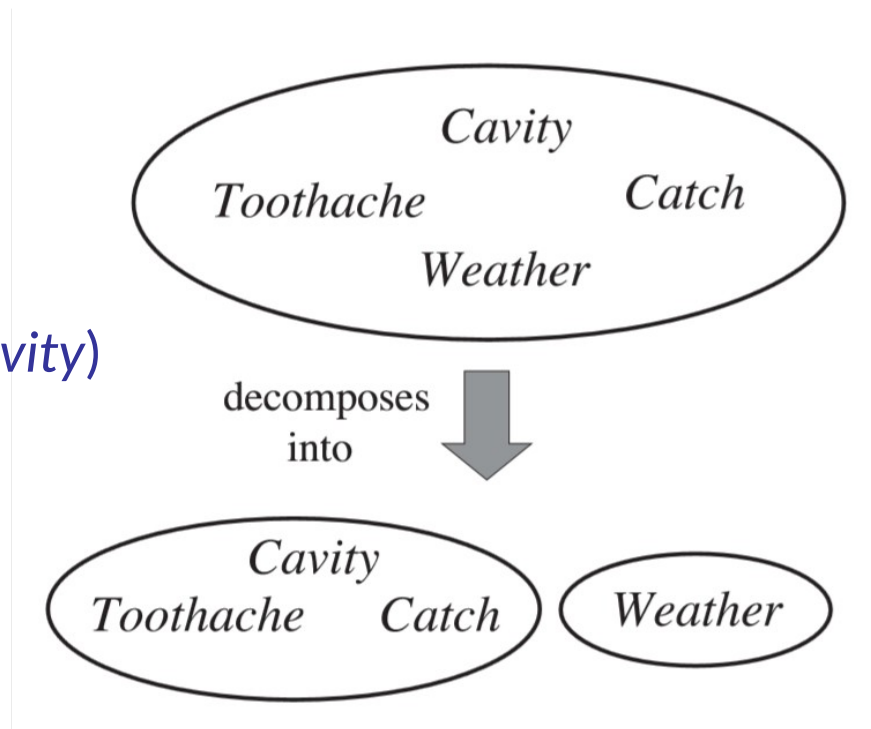
$$P(\text{Toothache}, \text{Catch}, \text{Cavity}, \text{Weather})$$

$$= P(\text{Weather} \mid \text{Toothache}, \text{Catch}, \text{Cavity}) P(\text{Toothache}, \text{Catch}, \text{Cavity})$$

$$= P(\text{Weather}) P(\text{Toothache}, \text{Catch}, \text{Cavity})$$

- Weather* 与其它三个变量之间相互独立

- 完全联合分布表中的 32 (8x4) 个条目可以降低为 12(8+4) 个



# 独立性

- 两个随机变量  $A$  和  $B$  之间独立，当且仅当：

$$P(A, B) = P(A) P(B) \quad \text{或} \quad P(A | B) = P(A) \quad \text{或} \quad P(B | A) = P(B)$$

- 独立性断言有助于减小问题域表示，并降低推理复杂度
- e.g., 可以假定 *Toothache* 和 *Weather* 之间相互独立

# 条件独立性

绝对独立性是强大的，但现实应用中很少。领域知识通常具有成百个变量，它们之间并不完全独立

- 条件独立性：

- 给定随机变量  $C$ ，两个随机变量  $A$  和  $B$  是条件独立的，当且仅当：

$$P(A, B | C) = P(A | C) P(B | C)$$

或  $P(A | B, C) = P(A | C)$

或  $P(B | A, C) = P(B | C)$

# 条件独立性

- 问题域：
  - Traffic
  - Umbrella
  - Raining



# 条件独立性

- 链式法则： $P(X_1, X_2, \dots, X_n) = P(X_1)P(X_2|X_1)P(X_3|X_1, X_2) \dots$

- 计算完全联合概率分布

$P(\text{Rain}, \text{Traffic}, \text{Umbrella})$

$= P(\text{Rain}) P(\text{Traffic} | \text{Rain}) P(\text{Umbrella} | \text{Rain}, \text{Traffic})$  （链式法则）

$= P(\text{Rain}) P(\text{Traffic} | \text{Rain}) P(\text{Umbrella} | \text{Rain})$  （条件独立的假设）

- 条件独立假设表示的方法：贝叶斯网络 / 图模型



# 小结

---

- 由于环境可能是部分可观察的或不确定的，智能体需要处理不确定性。
- 概率是描述不确定知识的一种严格形式。通过条件概率，将命题与智能体自身的知识联系起来
- 给定一个完全联合分布可以计算该问题域中任何命题的概率，但对复杂领域，需要找到一种方法来降低联合概率的数目
- 独立性和条件独立性提供了重要工具

---

谢谢！